quantil | matemáticas aplicadas

Metodologías de detección de anomalías basadas en métodos de aprendizaje supervisado y no supervisado.
Caso de uso: EMCALI

Elaborado por Quantil

Presentado a

DISICO

Febrero de 2026

Índice

1. Resumen Ejecutivo **3**

2. Introducción **3**

2.1. Contexto del Problema y Valor Económico 3

2.2. Propuesta de Valor: Un Enfoque Tridimensional 4

3. Preparación de Datos **5**

3.1. Proceso de Curación y Estructuración 5

3.2. Criterios de Exclusión y Normalización 5

4. Metodología **7**

4.1. Métodos Basados en Agrupación 7

4.2. Métodos Individuales: Análisis Longitudinal de Series Temporales 8

4.3. Evaluación de Métodos No Supervisados 9

4.4. Evaluación de Métodos No Supervisados 9

4.4.1. Procedimiento de Evaluación 10

4.4.2. Métricas de Evaluación: Precision@K, Recall@K y AP 10

4.4.3. Resultados Comparativos de Métodos No Supervisados 11

4.5. Modelos Supervisados 12

4.5.1. Definición del Esquema de Etiquetado 13

4.6. Entrenamiento de modelos 14

4.7. Métricas de Evaluación y Trade-offs Operativos 15

5. Resultados: Desempeño Comprobado y Valor Demostrable **16**

5.1. Entregables Concretos y Formato de Resultados 16

5.2. Desempeño de Modelos Supervisados 18

6. Análisis de Impacto Económico **20**

6.1. Metodología de Cuantificación de Beneficios 20

6.2. Resultados Económicos 22

7. Conclusiones y Recomendaciones Estratégicas 22

7.1. Síntesis de Hallazgos y Valor Diferencial 22

7.2. Recomendaciones para Implementación y Escalamiento 23

7.3. Oportunidades de Extensión y Mejora Continua 24

7.4. Mensaje Final: Una Inversión en Inteligencia Operativa 25

1. Resumen Ejecutivo

La detección de anomalías en el consumo eléctrico representa una de las oportunidades de mayor impacto financiero y operativo para las empresas de servicios públicos en América Latina. En el contexto de EMCALI, los diferentes segmentos de actividad económica —comercial, industrial, oficial y otros usos no residenciales— presentan características particulares que los convierten en áreas prioritarias para la implementación de tecnologías avanzadas de análisis de datos. Es por esto que Quantil ha desarrollado una solución integral que combina lo mejor de tres mundos metodológicos: técnicas de aprendizaje no supervisado basadas en agrupación, métodos de análisis individual de series temporales, y algoritmos supervisados de clasificación entrenados con casos históricos validados en campo.

Esta propuesta es una herramienta estratégica de negocio diseñada para maximizar la recuperación de ingresos, optimizar la asignación de recursos de inspección y reducir significativamente las pérdidas no técnicas. Los resultados preliminares demuestran una capacidad de detección superior al 70 %, con el potencial de identificar patrones fraudulentos tanto a nivel individual como colectivo, lo que multiplica exponencialmente el impacto de cada inspección realizada.

La arquitectura modular de nuestra solución permite su implementación gradual, comenzando con los usuarios de mayor riesgo identificados por nuestros algoritmos, generando retornos de inversión medibles desde las primeras semanas de operación. Además, el sistema aprende continuamente de cada visita de campo, refinando sus predicciones y mejorando su precisión con cada ciclo de validación, lo que garantiza una mejora sostenida en el tiempo del desempeño operativo. Esta metodología es aplicable a cualquier segmento de actividad económica, adaptándose a las particularidades de consumo de cada tipo de usuario.

2. Introducción

2.1. Contexto del Problema y Valor Económico

El consumo irregular de energía eléctrica en los diferentes segmentos de actividad económica de EMCALI —comercial, industrial, oficial y otros usos no residenciales— no es meramente un problema técnico o administrativo. Esto representa una amenaza directa a la sostenibilidad financiera de la operación y a la equidad del sistema tarifario. Cada kilovatio-hora no facturado debido a fraude, manipulación de medidores, conexiones irregulares o fallas técnicas no detectadas se traduce en pérdidas directas que erosionan los márgenes operativos y distorsionan la estructura de costos de la empresa.

Lo que hace particularmente críticos estos segmentos de actividad económica es la magnitud de su consumo promedio. A diferencia de los usuarios residenciales, donde las anomalías individuales pueden representar pérdidas relativamente moderadas, un solo establecimiento comercial, una planta industrial o una institución oficial con consumo irregular puede generar impactos económicos equivalentes a decenas o incluso cientos de usuarios residenciales. Más aún, la naturaleza de estos usuarios (desde pequeños comercios hasta grandes industrias, restaurantes,

hoteles, centros de servicios, instituciones públicas y complejos manufactureros) introduce una heterogeneidad en los patrones de consumo que hace insuficientes los métodos tradicionales de detección basados en umbrales fijos o análisis unidimensionales.

Este proyecto surge del reconocimiento de que las metodologías convencionales de auditoría y control, basadas principalmente en inspecciones aleatorias o denuncias puntuales, resultan ineficientes frente a la escala del desafío. Así, la pregunta que orienta el desarrollo del proyecto es: ¿cómo identificar, entre miles de usuarios de diferentes actividades económicas, aquellos que con mayor probabilidad presentan anomalías que justifican una inspección de campo? La respuesta requiere no solo de algoritmos sofisticados, sino de un entendimiento profundo del comportamiento eléctrico de cada segmento de actividad y de la capacidad de traducir señales estadísticas en acciones operativas concretas y priorizadas.

2.2. Propuesta de Valor: Un Enfoque Tridimensional

La solución se distingue por integrar tres enfoques metodológicos complementarios que, trabajando en conjunto, ofrecen una cobertura diagnóstica sin precedentes. Esta arquitectura tridimensional responde a la naturaleza multifacética de las anomalías en el consumo eléctrico de varias actividades económicas, donde diferentes tipos de irregularidades exhiben distintas firmas estadísticas que requieren herramientas especializadas para su detección.

El primer componente metodológico se centra en la detección de anomalías mediante técnicas de agrupación por similaridad. Este enfoque reconoce que usuarios con características similares —geográficas, técnicas o socioeconómicas— deberían exhibir patrones de consumo comparables. La metodología consiste en agrupar usuarios semejantes y, dentro de cada grupo, identificar aquellos cuyo comportamiento se desvía significativamente del patrón colectivo de sus pares. Un usuario conectado al mismo transformador que sus vecinos pero con consumo marcadamente diferente, o un establecimiento industrial que se comporta de manera atípica respecto a industrias similares en la misma zona, constituye una anomalía detectada por contraste con su grupo de referencia. Este enfoque es particularmente poderoso porque proporciona un *benchmark* contextualizado: lo que es normal para un grupo puede ser anómalo para otro, permitiendo detectar irregularidades que serían invisibles en análisis sin referencia comparativa. Adicionalmente, cuando varios usuarios dentro de un mismo grupo resultan anómalos simultáneamente —por ejemplo, múltiples usuarios en un transformador— esto puede señalar problemas estructurales o fallas en la infraestructura compartida que amplifican el valor de una intervención focalizada.

El segundo componente se enfoca en el análisis individual de cada usuario mediante técnicas avanzadas de series temporales. Aquí el objetivo es capturar cambios estructurales en el comportamiento de consumo que podrían pasar desapercibidos en análisis transversales o grupales. Un establecimiento comercial que históricamente consumía entre 800 y 1000 kWh mensuales y súbitamente reduce su consumo a 300 kWh sin justificación aparente, o una planta industrial que disminuye drásticamente su demanda sin reportar paros de producción, representan anomalías temporales que los modelos están diseñados para detectar. Estos métodos son particularmente efectivos para identificar manipulaciones recientes de medidores, cambios no autorizados en las instalaciones eléctricas, o desvíos de energía que alteran abruptamente el perfil de consumo del

usuario.

El tercer componente es la implementación de modelos supervisados de clasificación entrenados con casos históricos validados. Así, en lugar de depender exclusivamente de desviaciones estadísticas genéricas, los algoritmos aprenden directamente de la experiencia acumulada de EMCALI en inspecciones pasadas. Cada caso investigado y confirmado como fraude se convierte en conocimiento estructurado que alimenta los modelos de *machine learning*, permitiéndoles identificar patrones sutiles y combinaciones de variables que distinguen a los usuarios fraudulentos de aquellos con consumos legítimos pero variables. Este enfoque supervisado genera *scores* de probabilidad de anomalía calibrados con la realidad operativa específica de EMCALI, lo que se traduce en listas priorizadas de inspección con altas tasas de efectividad, adaptables a las particularidades de cada segmento de actividad económica.

3. Preparación de Datos

3.1. Proceso de Curación y Estructuración

La calidad de cualquier solución de *machine learning* está fundamentalmente limitada por la calidad de los datos con los que se entrena y opera. En este proyecto, se dedicaron recursos significativos a un proceso de curación, limpieza y estructuración de la información, reconociendo que este es el cimiento sobre el cual se construye la precisión predictiva de los modelos. La base de datos original de EMCALI presenta, como es típico en sistemas de información de servicios públicos, algunos desafíos de calidad que deben ser sistemáticamente abordados antes de proceder con cualquier análisis estadístico o entrenamiento de algoritmos.

La transformación de la estructura de datos original a un formato de series temporales es el primer paso fundamental. Los sistemas de facturación típicamente almacenan la información en formato transaccional o relacional, donde cada registro corresponde a una lectura individual. Para el propósito analítico, se requirió reorganizar esta información de modo que cada usuario estuviera representado por una serie temporal completa de sus consumos mensuales, preservando la secuencialidad y permitiendo el análisis de tendencias, estacionalidades y cambios estructurales. Esta reorganización requirió manejar adecuadamente periodos con lecturas faltantes, ciclos de facturación irregulares, y otros ajustes que pueden introducir valores atípicos espurios.

3.2. Criterios de Exclusión y Normalización

Una vez estructurados los datos como series temporales, se implementaron criterios de exclusión diseñados para eliminar casos que no aportan valor analítico o que podrían introducir sesgos sistemáticos. El primer criterio fue la eliminación de series con varianza nula, es decir, usuarios cuyo consumo registrado permanece constante durante todo el periodo de análisis. Estos casos, aunque infrecuentes, pueden corresponder a usuarios con consumos estimados por períodos prolongados, medidores bloqueados o errores de captura sistemáticos. Su inclusión distorsionaría los análisis de agrupación y los modelos de series temporales, que asumen inherentemente cierta

variabilidad en los datos.

El segundo criterio de exclusión se enfocó en series con alta proporción de valores nulos o faltantes. La presencia ocasional de lecturas faltantes es manejable mediante técnicas de imputación, pero cuando la información disponible es excesivamente fragmentada, por ejemplo, un usuario con solo 3 o 4 lecturas válidas en un año, resulta imposible caracterizar adecuadamente su patrón de consumo o detectar anomalías con confianza estadística. Por ello, se establecieron umbrales mínimos de completitud que garantizan que cada usuario analizado cuenta con suficiente historia para soportar inferencias robustas.

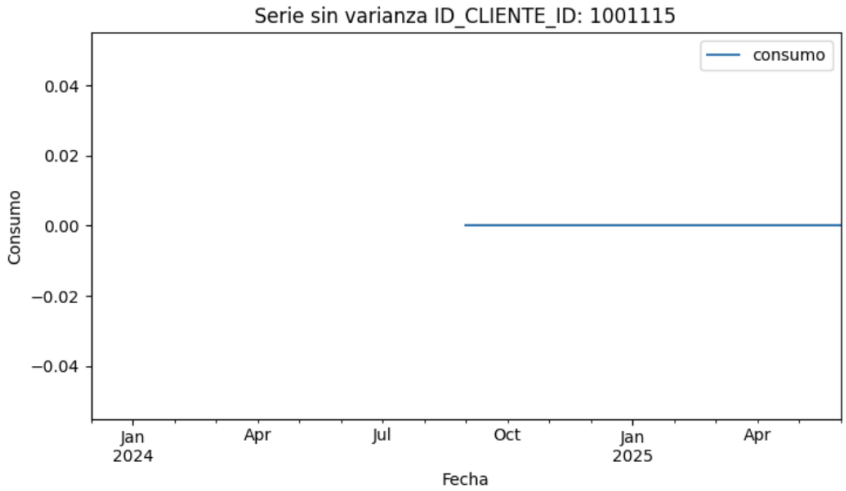

Figura 1: Serie de tiempo de consumo de usuario sin varianza.

Un criterio de exclusión particularmente importante desde la perspectiva del negocio fue la remoción de usuarios con cambios recientes de medidor. Estos usuarios típicamente fueron identificados previamente como anómalos, lo que motivó la intervención y reemplazo del equipo de medición. Mantenerlos en el análisis crearía un sesgo de selección problemático: por un lado, contaminarían el entrenamiento de modelos supervisados al representar casos ya resueltos; por otro, sus historiales de consumo mostrarían discontinuidades abruptas (antes y después del cambio) que activarían artificialmente los métodos de detección de anomalías, generando alertas sobre casos ya gestionados. La exclusión de estos usuarios garantiza que los modelos se enfoquen en la identificación de nuevas anomalías no detectadas previamente.

Finalmente, la normalización de los consumos es esencial para hacer comparables usuarios con escalas radicalmente diferentes, especialmente considerando la heterogeneidad entre diferentes actividades económicas. Un pequeño comercio puede consumir 200 kWh mensuales, mientras que una planta industrial puede consumir 500,000 kWh, y una institución oficial puede estar en cualquier punto de este espectro. Sin normalización, los algoritmos de agrupación y detección estarían dominados por las diferencias de escala, ignorando patrones de comportamiento más sutiles pero igualmente relevantes. Se implementaron transformaciones que preservan la información sobre patrones temporales y variabilidad relativa, mientras eliminan el efecto de la escala absoluta de consumo, permitiendo que un pequeño comercio con consumo anómalo relativo a su historia sea detectado con la misma sensibilidad que una gran industria con desviaciones proporcionales.

4. Metodología

4.1. Métodos Basados en Agrupación

Los métodos basados en agrupación están fundamentados en un principio estadístico robusto: usuarios que comparten características contextuales relevantes exhiben patrones de consumo comparables dentro de su segmento. Cuando un usuario se desvía significativamente del comportamiento de su grupo de referencia, esta desviación constituye una señal de alto valor predictivo que merece investigación. La potencia de este enfoque radica en la capacidad para detectar anomalías relativas que serían invisibles en análisis individuales fuera del contexto.

Se desarrollaron dos estrategias complementarias de agrupación, cada una capturando diferentes dimensiones de similitud entre usuarios. La primera estrategia se basa en características socioeconómicas y urbanas: municipio, estrato socioeconómico, barrio y tipo de actividad económica (comercial, industrial, oficial, entre otros). Esta agrupación reconoce que el contexto socioeconómico y geográfico es un determinante fundamental del perfil de consumo. Un restaurante en un barrio de estrato alto tendrá patrones de consumo naturalmente diferentes a uno en una zona popular, así como una pequeña fábrica tendrá consumos distintos a una gran planta industrial. Al agrupar usuarios en contextos similares, se establecen *benchmarks* realistas y localmente calibrados para cada tipo de actividad.

La segunda estrategia de agrupación se enfoca en características técnico-geográficas, específicamente la asociación de usuarios al transformador que los alimenta. En este caso, los usuarios conectados a un mismo transformador no solo comparten proximidad física extrema, sino también características de la red eléctrica: calidad de voltaje, topología de conexión, y exposición a condiciones operativas comunes. Más importante aún, este criterio es extraordinariamente efectivo para detectar fraudes organizados o fallas sistemáticas en infraestructura. Si cinco de siete usuarios —sean comerciales, industriales u oficiales— conectados a un transformador exhiben simultáneamente consumos anómalos, la probabilidad de que exista un problema colectivo (manipulación del transformador, conexiones irregulares sistemáticas, o falla de medición masiva) es alta, y la intervención en ese transformador puede resolver múltiples casos de una sola vez.

Dentro de cada grupo, se aplicaron dos algoritmos de detección. El primero, *Isolation Forest*, un método basado en la intuición de que las observaciones anómalas son más fáciles de aislar mediante particiones aleatorias del espacio de características. El algoritmo construye múltiples árboles de decisión aleatorios donde en cada nodo se realiza una partición de una variable seleccionada al azar. Las observaciones anómalas requieren significativamente menos particiones para quedar aisladas en nodos terminales, lo que se traduce en un *score* de anomalía. Este método es particularmente robusto ante la presencia de múltiples variables, maneja naturalmente interacciones no lineales, y no requiere asumir distribuciones específicas para los datos, lo que lo hace ideal para el contexto de consumos eléctricos comerciales donde las distribuciones son frecuentemente asimétricas y multimodales.

El segundo algoritmo implementado es el *Modelo Gaussiano Multivariante*, inspirado en la metodología propuesta por Kharal et al. (2021) específicamente para detección de fraude en consumo

eléctrico en países en desarrollo. Este enfoque asume que los consumos normales dentro de un grupo siguen una distribución gaussiana multivariante, caracterizada por un vector de medias y una matriz de covarianzas. Una vez estimados estos parámetros a partir de los usuarios normales del grupo, es posible calcular la verosimilitud de cada observación bajo esta distribución. Usuarios con verosimilitudes extremadamente bajas, es decir, cuyos patrones de consumo son muy improbables bajo el modelo gaussiano del grupo, son clasificados como anómalos. Este método tiene la ventaja de proporcionar una interpretación probabilística directa y de capturar naturalmente las correlaciones entre diferentes características de consumo.

4.2. Métodos Individuales: Análisis Longitudinal de Series Temporales

En paralelo, se implementaron métodos que analizan la consistencia interna de cada serie temporal individual. Estos métodos son indispensables porque ciertas anomalías se manifiestan como cambios estructurales en el comportamiento de un usuario específico, independientemente de cómo se comporten otros usuarios en su grupo. Un establecimiento que mantiene un consumo estable de 1,200 kWh mensuales durante dos años y súbitamente cae a 400 kWh, una planta industrial que reduce su demanda de 100,000 kWh a 30,000 kWh sin reportar cambios operativos, o una institución oficial que duplica su consumo sin justificación, pueden estar experimentando anomalías legítimas (cierre temporal, cambio de actividad, expansión) o ilegítimas (manipulación de medidor, derivación de carga), pero en cualquier caso, son cambios estructurales que deben ser verificados.

El primer método individual implementado es *CUSUM* (Cumulative Sum Control Chart), una técnica clásica de control estadístico de procesos que fue originalmente desarrollada para manufactura pero que resulta extraordinariamente efectiva para detectar cambios en la media de series temporales de consumo eléctrico. CUSUM funciona acumulando desviaciones de la media histórica del usuario: si el consumo actual es menor que la media, la suma acumulada decrece; si es mayor, crece. Un cambio estructural sostenido en el nivel de consumo se manifiesta como una tendencia persistente en la serie CUSUM, que cruza umbrales estadísticamente calibrados indicando un cambio significativo. La ventaja de CUSUM sobre simples comparaciones de medias es su sensibilidad a cambios graduales: puede detectar reducciones del 20-30 % en consumo que se instalan progresivamente en 3-4 meses, situaciones que métodos menos sofisticados podrían no identificar hasta que la desviación sea mucho más evidente.

El segundo conjunto de métodos individuales se basa en modelación explícita de series temporales mediante algoritmos de forecasting. Se implementaron tres familias de modelos complementarios: SARIMAX (Seasonal AutoRegressive Integrated Moving Average with eXogenous variables), ETS (Error-Trend-Seasonal), y Prophet. Cada uno de estos enfoques tiene fortalezas específicas. SARIMAX es particularmente efectivo cuando los consumos exhiben estacionalidad clara y componentes autorregresivos fuertes, por ejemplo, restaurantes con patrones semanales consistentes, industrias con ciclos de producción regulares, o instituciones educativas con consumos marcadamente diferentes en periodos lectivos versus vacaciones. ETS es robusto ante cambios graduales en la tendencia y maneja bien series con estacionalidad multiplicativa. Prophet, desarrollado por Facebook, es especialmente efectivo para series con estacionalidades múltiples y maneja automáticamente días festivos y eventos especiales.

El proceso de detección con estos modelos es el siguiente: para cada usuario comercial, se entrena el modelo con su historia de consumo hasta el periodo *t-1*, se genera una predicción puntual para el periodo t junto con su intervalo de confianza (típicamente al 95 %), y se compara el consumo observado contra este intervalo. Un consumo que cae significativamente fuera del intervalo de predicción, particularmente si es persistentemente bajo durante múltiples periodos consecutivos, constituye una anomalía estadísticamente significativa. La magnitud de la desviación respecto al límite inferior del intervalo se cuantifica en un *score* que permite priorizar los casos más extremos. Este enfoque tiene la ventaja de ser específico para cada usuario: un mismo consumo absoluto puede ser normal para un usuario y anómalo para otro, dependiendo de sus historiales respectivos.

Un refinamiento importante de la implementación es el uso de modelos *ensemble*: en lugar de delegar la decisión final a un único algoritmo de *forecasting*, se combinan las predicciones de SARIMAX, ETS y Prophet mediante votación ponderada. Un consumo es marcado como altamente anómalo solo si múltiples modelos coinciden en que está fuera de lo esperado. Este enfoque *ensemble* reduce significativamente los falsos positivos que inevitablemente genera cualquier modelo individual, lo que aumenta la confiabilidad de las alertas para los equipos de inspección de campo.

4.3. Evaluación de Métodos No Supervisados

Los métodos no supervisados de detección de anomalías —tanto grupales (Isolation Forest, Modelo Gaussiano Multivariante) como individuales (CUSUM, SARIMAX, ETS, Prophet)— generan rankings de usuarios ordenados por scores de anomalía sin conocimiento previo de qué usuarios son efectivamente fraudulentos. Para evaluar la efectividad de estos métodos en identificar casos reales de irregularidades, es necesario contrastar sus predicciones contra el conjunto de usuarios que fueron visitados en campo y cuyo estado fue verificado mediante inspección física. Esta validación empírica permite cuantificar qué tan bien cada método prioriza los usuarios verdaderamente anómalos en las posiciones superiores de su ranking.

4.4. Evaluación de Métodos No Supervisados

Los métodos no supervisados de detección de anomalías —tanto grupales (Isolation Forest, Modelo Gaussiano Multivariante) como individuales (CUSUM, SARIMAX, ETS, Prophet)— generan rankings de usuarios ordenados por scores de anomalía sin conocimiento previo de qué usuarios son efectivamente fraudulentos. Para evaluar la efectividad de estos métodos en identificar casos reales de irregularidades, es necesario contrastar sus predicciones contra el conjunto de usuarios que fueron visitados en campo y cuyo estado fue verificado mediante inspección física. Esta validación empírica permite cuantificar qué tan bien cada método prioriza los usuarios verdaderamente anómalos en las posiciones superiores de su ranking.

4.4.1. Procedimiento de Evaluación

Dado que estos métodos generan rankings completos de todos los usuarios sin conocimiento previo de las etiquetas verdaderas, la evaluación se realiza a posteriori mediante el cruce de sus predicciones con los registros de inspecciones de campo que constituyen el *ground truth*.

El procedimiento se estructura en los siguientes pasos:

1. Filtrado a usuarios inspeccionados: Del ranking completo producido por cada modelo se conservan únicamente aquellos usuarios que cuentan con registros de inspección de campo verificada. El orden relativo asignado por el modelo se preserva: el usuario inspeccionado que el modelo rankeó más alto en su lista original queda en la primera posición de la lista filtrada, y así sucesivamente. Este filtrado es necesario porque solo podemos evaluar el desempeño del modelo en casos donde conocemos el estado verdadero del usuario.

2. Truncamiento a TOP_K: De la lista filtrada de usuarios inspeccionados ordenados según el modelo, se toman únicamente los primeros 5,000 casos (TOP_K = 5,000). Este truncamiento simula el escenario operativo realista en el que el equipo de inspecciones de EMCALI solo puede atender una cantidad limitada de casos en un ciclo operativo dado. El valor de TOP_K es idéntico para todos los modelos evaluados, lo que garantiza comparaciones justas bajo las mismas restricciones de capacidad.

3. Definición del universo de evaluación: Únicamente se analizan los resultados sobre los TOP_K = 5,000 usuarios inspeccionados rankeados.

4. Cálculo de métricas: Sobre la lista de TOP_K usuarios inspeccionados ordenados según el ranking del modelo, se calculan métricas de desempeño para diferentes valores de k que representan distintos escenarios de capacidad operativa: $k \in \{50, 100, 500, 1000, 2000, 3000, 4000, 5000\}$. Este diseño permite caracterizar cómo evoluciona el desempeño del modelo a medida que se profundiza en el ranking, desde inspecciones altamente focalizadas ($k = 50$) hasta campañas exhaustivas que agotan la capacidad disponible ($k = 5000$).

4.4.2. Métricas de Evaluación: Precision@K, Recall@K y AP

Para cada valor de k, se calculan tres métricas complementarias que capturan diferentes aspectos del desempeño del ranking:

Precision@k mide qué proporción de los primeros k usuarios señalados por el modelo son efectivamente anomalías reales confirmadas mediante inspección:

$$\text{Precision@k} = \frac{|\text{anomalías reales en los primeros } k|}{k} \tag{1}$$

Esta métrica responde a la pregunta operativa: si decido inspeccionar los k usuarios con mayor score de anomalía según este método, ¿qué tasa de éxito puedo esperar?

Recall@k mide qué proporción del total de anomalías reales presentes en el universo TOP_K son recuperadas dentro de los primeros k casos:

$$\text{Recall@k} = \frac{|\text{anomalías reales en los primeros } k|}{|\text{anomalías reales en TOP_K}|} \tag{2}$$

Esta métrica responde a: ¿qué fracción de las anomalías disponibles para detectar estoy capturando con las primeras k inspecciones?

Average Precision (AP) proporciona una evaluación integral del ranking completo, considerando no solo cuántas anomalías se recuperan sino también dónde específicamente están ubicadas en el ranking:

$$\text{AP} = \frac{1}{N_{\text{anómalos}}} \sum_{i=1}^{N} \text{Precision@i} \times \text{rel}(i) \tag{3}$$

donde N es el tamaño del ranking evaluado, $N_{\text{anómalos}}$ es el número total de anomalías reales en TOP_K, y rel(i) es una función indicadora que vale 1 si la posición i contiene una anomalía real y 0 en caso contrario. AP es equivalente al área bajo la curva precisión-recall discreta y resume el desempeño global del método en un solo número.

4.4.3. Resultados Comparativos de Métodos No Supervisados

La Tabla 1 presenta los resultados de evaluación de los métodos no supervisados implementados. Los scores de cada método fueron ordenados de mayor a menor (mayor score indica mayor sospecha de anomalía), filtrados a usuarios con inspecciones confirmadas, truncados a TOP_K = 5,000, y evaluados mediante las métricas descritas.

Método	**P@50**	**P@100**	**P@500**	**P@1000**	**P@5000**	**R@1000**	**AP**
Isolation Forest	0.380	0.410	0.422	0.441	0.437	0.209	**0.438**
Gaussian Multiv.	0.540	0.480	0.440	0.424	0.407	0.208	0.422
CUSUM	0.240	0.280	0.370	0.389	0.411	0.189	0.394
ETS	0.420	0.410	–	–	–	–	0.405

Cuadro 1: Evaluación de métodos no supervisados mediante Precision@K, Recall@K y AP. P@k indica la precisión (tasa de éxito) al inspeccionar los primeros k usuarios rankeados. R@1000 indica qué fracción del total de anomalías en TOP_K se recupera en las primeras 1,000 inspecciones. AP resume el desempeño global del ranking.

Los resultados revelan patrones distintivos de desempeño entre los métodos evaluados. **Isolation Forest** emerge como el método de mejor desempeño global con un AP de 0.438, seguido cercanamente por el Modelo Gaussiano Multivariante (AP = 0.422). Sin embargo, la comparación detallada por valores de k revela trade-offs importantes entre los métodos.

El **Modelo Gaussiano** exhibe una Precision@50 de 0.54, la más alta entre todos los métodos

evaluados. Esto indica que este algoritmo es particularmente efectivo para identificar los casos más extremos y prioritarios: más de la mitad de las primeras 50 inspecciones priorizadas por el método Gaussiano resultan en detección de anomalías. Sin embargo, esta precisión declina gradualmente a medida que se profundiza en el ranking: Precision@100 = 0.48, Precision@500 = 0.44, llegando a Precision@5000 = 0.407. Este patrón sugiere que el método Gaussiano es óptimo para escenarios donde la capacidad de inspección es muy limitada y se deben priorizar únicamente los casos de mayor confianza.

Isolation Forest, por contraste, exhibe un comportamiento diferente: aunque su Precision@50 = 0.38 es notablemente inferior a la del Gaussiano, su precisión se incrementa al profundizar en el ranking: Precision@100 = 0.41, Precision@500 = 0.422, Precision@1000 = 0.441, manteniéndose en 0.437 en k=5000. Este comportamiento indica que Isolation Forest es más robusto en rankings profundos: aunque no concentra tan dramáticamente las anomalías en las primeras posiciones como el Gaussiano, mantiene mejor su capacidad de discriminación a lo largo de todo el espectro de usuarios sospechosos. Esto lo hace preferible para campañas de inspección más amplias donde se procesarán 500+ casos.

CUSUM muestra el desempeño más débil entre los métodos grupales e individuales tradicionales, con AP = 0.394. Sus Precision@50 y Precision@100 son las más bajas (0.24 y 0.28 respectivamente), aunque experimenta una mejora gradual en rankings profundos, llegando a Precision@5000 = 0.411, comparable con los otros métodos. El Recall@1000 = 0.189 es también el más bajo, confirmando que CUSUM tiene mayor dificultad para priorizar anomalías en las primeras posiciones. Esto sugiere que los cambios estructurales detectados por CUSUM, aunque válidos, no siempre corresponden a las anomalías más severas o urgentes desde la perspectiva operativa de EMCALI.

ETS muestra resultados prometedores en las primeras posiciones (Precision@50 = 0.42, Precision@100 = 0.41), con un AP = 0.405 que lo posiciona por encima de CUSUM pero por debajo de los métodos grupales. Sin embargo, los datos para este método solo están disponibles hasta k=300 en la evaluación presentada, dado que el método no asigna un puntaje a los valores que no clasifica como anómalos.

4.5. Modelos Supervisados

La tercera columna de la arquitectura metodológica es la implementación de modelos supervisados de clasificación que aprenden directamente de la experiencia histórica de inspecciones de EMCALI. Este enfoque trasciende la detección de anomalías estadísticas puras para enfocarse en la identificación de patrones característicos de casos confirmados como fraudulentos o irregulares. La pregunta que responden estos modelos es fundamentalmente diferente a la de los métodos no supervisados: no preguntan "¿es este usuario diferente a su grupo?" sino "¿se parece este usuario a los casos que ya se inspeccionaron y se confirmaron como fraude?"

La construcción de estos modelos requirió primero la integración y etiquetado de datos históricos de inspecciones. Para un subconjunto significativo de usuarios comerciales, EMCALI cuenta con registros de visitas de campo realizadas en el pasado, incluyendo el resultado de cada inspección:

si se encontró evidencia de fraude, manipulación de medidor, conexiones irregulares, o si el usuario resultó estar operando normalmente. Cada uno de estos usuarios inspeccionados se convirtió en una observación etiquetada en el conjunto de entrenamiento: Clase 1 para casos confirmados como anómalos, Clase 0 para casos validados como normales. Este conjunto de datos etiquetados representa conocimiento adquirido a través de inspecciones físicas que tienen costo operativo significativo.

4.5.1. Definición del Esquema de Etiquetado

La construcción del conjunto de datos etiquetados requirió integrar dos fuentes de información históricas de inspecciones de EMCALI que utilizan esquemas de codificación diferentes para reportar los hallazgos de campo. Esta diferencia en nomenclaturas hizo necesario establecer un protocolo de estandarización que permitiera combinar ambas fuentes en un conjunto de entrenamiento coherente.

En la primera fuente de datos, denominada `INSPECCIONES_REALIZADAS.xlsx`, el campo `Anomalia 1` captura el hallazgo principal de cada visita y sigue un esquema binario relativamente simple. El código `CO - CONFORME` identifica usuarios que fueron inspeccionados sin encontrar irregularidades. El código `NA - NO APLICA` indica inspecciones que no pudieron completarse o donde el criterio de evaluación no era aplicable y estos registros se excluyen del conjunto de entrenamiento (anomalía = NaN) para evitar introducir ruido. Cualquier otro código de irregularidad reportado en esta base se etiqueta por defecto como anómalo (anomalía = 1), bajo el principio de que la documentación de una irregularidad específica por parte del inspector constituye evidencia de comportamiento que requiere corrección.

La segunda fuente corresponde a reportes históricos de irregularidades procesados mediante el archivo `lv_lega_insp`. Esta base utiliza un esquema de codificación más granular que distingue entre diferentes tipos de irregularidades técnicas. Sin embargo, el análisis de estos códigos reveló que ciertas categorías, aunque formalmente constituyen desviaciones respecto a normativas, no representan manipulaciones intencionales del sistema de medición que generen pérdidas económicas directas para EMCALI. Estas categorías incluyen: `16G - Medidor sin sello de bornera y/o rotos`, que indica ausencia o daño de sellos de seguridad pero no implica manipulación efectiva del consumo; `15 - Reconexión no autorizada registrada por el medidor`, que documenta reconexiones sin autorización formal pero donde el medidor continúa registrando correctamente el consumo post-reconexión; y `14 - Cambio de uso o tarifa inadecuada al tipo de cliente`, que identifica discrepancias administrativas-tarifarias donde el medidor funciona correctamente pero la tarifa aplicada no corresponde a la actividad económica real. Estas tres categorías reciben la etiqueta de no anómalo (anomalía = 0) en la base histórica, reconociendo que son irregularidades que requieren corrección administrativa pero no fraude técnico activo.

Adicionalmente, la base histórica contiene el código `16 - OTRO`, una categoría residual que captura hallazgos heterogéneos que no encajan en clasificaciones estándar. Dado que su naturaleza es indefinida y potencialmente incluye tanto casos irrelevantes como situaciones ambiguas, estos registros se excluyen completamente antes del proceso de etiquetado para mantener la calidad

del conjunto de entrenamiento. Cualquier otro código de irregularidad en esta base histórica se etiqueta como anómalo (anomalía = 1).

4.6. Entrenamiento de modelos

A partir de las series temporales de estos usuarios etiquetados, se deriva un conjunto extenso de características (*features*) agregadas diseñadas para capturar diferentes dimensiones del comportamiento de consumo. Estas características incluyen estadísticas descriptivas básicas (consumo promedio, mediana, máximo, mínimo), medidas de variabilidad (desviación estándar, coeficiente de variación, rango intercuartílico), indicadores de tendencia (pendiente de regresión lineal, presencia de tendencia decreciente significativa), factores de estacionalidad (amplitud de variación mensual, consistencia de patrones estacionales), y características más sofisticadas derivadas de análisis de series temporales (coeficientes de autocorrelación, entropía de la serie, indicadores de cambios estructurales). Aquí se traduce información temporal compleja en un vector de números que los algoritmos de *machine learning* pueden procesar efectivamente.

Sobre este conjunto de características derivadas, se entrenaron tres algoritmos de clasificación del estado del arte en *machine learning*: *Random Forest, XGBoost* y *LightGBM.*

Random Forest es un método *ensemble* que construye múltiples árboles de decisión, cada uno entrenado sobre una muestra *bootstrap* del conjunto de datos y considerando en cada nodo una selección aleatoria de variables. La clasificación final para un usuario se obtiene por votación mayoritaria de todos los árboles. Este procedimiento de *bagging* (bootstrap aggregating) reduce sustancialmente la varianza del modelo y lo hace altamente robusto ante *overfitting*, al tiempo que permite capturar relaciones no lineales arbitrariamente complejas entre las características y la probabilidad de anomalía. *Random Forest* también proporciona medidas de importancia de variables que permiten entender qué características son más predictivas de fraude, lo cual tiene valor para interpretabilidad y comunicación con stakeholders.

XGBoost (Extreme Gradient Boosting) representa una familia de algoritmos basados en boosting, donde los árboles de decisión se construyen secuencialmente, con cada árbol nuevo intentando corregir los errores de los árboles anteriores. El proceso de optimización se realiza mediante *gradient descent* sobre una función de pérdida definida, incorporando términos de regularización L1 y L2 que penalizan la complejidad del modelo y ayudan a prevenir *overfitting.* *XGBoost* es particularmente efectivo cuando existe desbalance entre clases (casos anómalos mucho menos frecuentes que casos normales), gracias a sus capacidades de ponderación de clases y ajuste de umbrales de clasificación. Además, maneja automáticamente valores faltantes y es computacionalmente muy eficiente incluso con conjuntos de datos grandes.

LightGBM (Light Gradient Boosting Machine) es una variante avanzada de *gradient boosting* desarrollada por Microsoft que introduce dos innovaciones clave: crecimiento de árboles por hojas (leaf-wise) en lugar de por niveles (level-wise), y uso de histogramas discretizados para las variables continuas. Estas optimizaciones hacen a *LightGBM* significativamente más rápido que *XGBoost*, lo que permite entrenar modelos con muchas más variables y observaciones en el mismo tiempo computacional. Esta eficiencia es crucial en este contexto, donde existen decenas

de miles de usuarios comerciales y potencialmente cientos de características derivadas. *LightGBM* también maneja naturalmente variables categóricas y proporciona regularización sofisticada para evitar overfitting.

Cabe resaltar que el proceso de entrenamiento de estos modelos siguió un protocolo de validación. En particular, se dividió el conjunto de usuarios etiquetados en subconjuntos de entrenamiento (70 %), validación (15 %) y prueba (15 %), preservando la proporción de clases en cada partición mediante *stratified sampling*. Los modelos fueron entrenados en el conjunto de entrenamiento, con hiperparámetros optimizados mediante validación cruzada y búsqueda sistemática en el conjunto de validación, y finalmente evaluados en el conjunto de prueba completamente independiente para obtener estimaciones no sesgadas de su desempeño en datos nunca vistos.

4.7. Métricas de Evaluación y Trade-offs Operativos

La evaluación de modelos de clasificación en contextos de negocio como este requiere ir más allá de métricas agregadas simples como la exactitud (accuracy). Si bien la exactitud es informativa (representa la fracción de usuarios correctamente clasificados) no captura aspectos críticos del desempeño que tienen implicaciones operativas directas. En este caso, es esencial entender la matriz de confusión completa, que desagrega los aciertos y errores del modelo en cuatro categorías: Verdaderos Positivos (VP), Verdaderos Negativos (VN), Falsos Positivos (FP) y Falsos Negativos (FN).

Los Falsos Negativos —usuarios anómalos que el modelo clasifica como normales— representan oportunidades perdidas: son casos de fraude o irregularidad que continúan sin detectarse y siguen generando pérdidas para EMCALI. El costo de un falso negativo es el valor de la energía no facturada que continúa sin cobrarse hasta que eventualmente el caso sea detectado por otros medios o permanezca indefinidamente sin detectar. Los Falsos Positivos —usuarios normales que el modelo clasifica como anómalos— representan ineficiencia operativa: son inspecciones de campo que se realizan sin encontrar irregularidades, consumiendo tiempo y recursos del equipo técnico sin generar recuperación de ingresos. El costo de un falso positivo es el costo operativo de la inspección más el potencial costo reputacional si las inspecciones infundadas afectan la relación con clientes comerciales legítimos.

El desempeño óptimo del modelo depende del balance entre estos dos tipos de errores, lo cual es función de la estrategia operativa de EMCALI. Si el objetivo es maximizar la tasa de recuperación y los recursos de inspección son relativamente abundantes, puede ser óptimo aceptar una tasa más alta de falsos positivos a cambio de minimizar falsos negativos. Si por el contrario, la capacidad de inspección es limitada y cada visita de campo tiene un costo alto, puede preferirse un modelo más conservador que genere menos falsos positivos aun a costa de dejar algunos falsos negativos sin detectar inicialmente.

Estos modelos proporcionan no solo una clasificación binaria (anómalo/normal), sino un score de probabilidad continuo entre 0 y 1 que representa la confianza del modelo en que el usuario es anómalo. Este *score* permite a EMCALI ajustar dinámicamente el umbral de clasificación según sus prioridades operativas. Por ejemplo, estableciendo un umbral alto (≈ 0.7) se genera

una lista de inspección de alta precisión donde la mayoría de casos inspeccionados resultarán anómalos, mientras que un umbral más bajo (≈0.4) genera una lista más larga con mayor cobertura pero menor tasa de éxito. Esta flexibilidad es fundamental para adaptar el sistema a diferentes escenarios operativos.

5. Resultados: Desempeño Comprobado y Valor Demostrable

5.1. Entregables Concretos y Formato de Resultados

Como entregable tangible de este proyecto, se proporcionó una carpeta comprimida que contiene archivos en formato Excel con los 100 usuarios más anómalos identificados por cada una de nuestras metodologías. Esta estructura permite a EMCALI acceder a los resultados de forma inmediata y operativa, sin requerir infraestructura técnica compleja o conocimientos especializados de ciencia de datos. Cada archivo puede ser utilizado para generar órdenes de inspección, priorizar el trabajo de campo, o analizar patrones geográficos y técnicos de las anomalías detectadas en cualquier segmento de actividad económica.

Para cada metodología implementada —Isolation Forest por grupos socioeconómicos, Modelo Gaussiano por grupos socioeconómicos, Isolation Forest por transformador, Modelo Gaussiano por transformador, CUSUM, SARIMAX, ETS, Prophet, Random Forest, XGBoost y LightGBM— se proporcionaron dos variantes de resultados. La primera variante considera la totalidad de usuarios analizados, proporcionando una visión completa del universo de cada actividad económica. La segunda variante excluye usuarios con cambio reciente de medidor, enfocándose en anomalías nuevas no previamente detectadas, lo cual es particularmente útil para la planificación de inspecciones incrementales.

Cada archivo incluye para cada usuario identificado un conjunto de información esencial: código de suministro, dirección, barrio, tipo de actividad económica, transformador asociado, historial de consumos recientes, y crucialmente, un *score* de anomalía. Este *score* puede interpretarse como una medida cuantitativa de la severidad o probabilidad de que el consumo registrado corresponda efectivamente a un comportamiento irregular. Así, *Scores* más altos indican mayor confianza del modelo en que el usuario requiere inspección. Esta cuantificación permite no solo identificar casos anómalos, sino priorizarlos objetivamente según su probabilidad estimada de ser verdaderos positivos, independientemente de si se trata de un comercio, una industria o una institución oficial.

A continuación se muestran algunos ejemplos de clientes anómalos identificados por los métodos descritos anteriormente. La Figura 2 muestra el comportamiento de un cliente que es potencial anómalo determinado por el análisis de cambio estructural, por medio del algoritmo CUSUM.

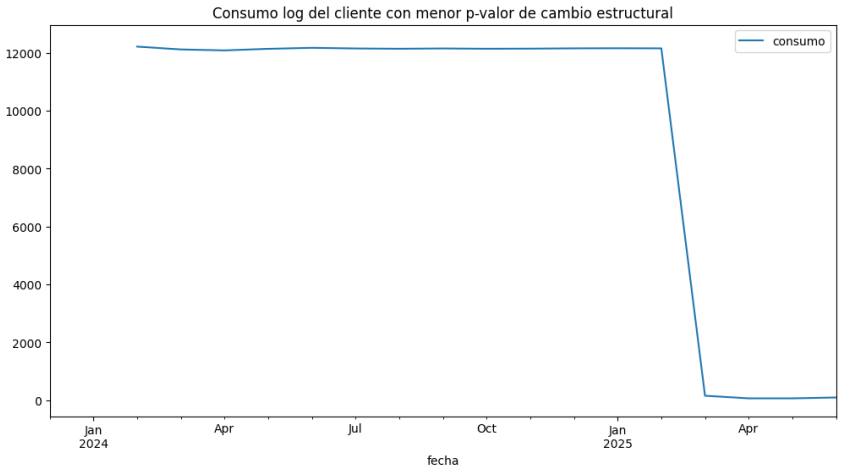

Figura 2: Ejemplo de cliente anómalo detectado por algoritmo CUSUM, cambio estructural

A diferencia de los métodos individuales, por medio de los métodos de agrupación se pueden revelar patrones como los que muestra la Figura 3. Esta Figura es una representación 2-dimensional de las características evaluadas por el algoritmo.

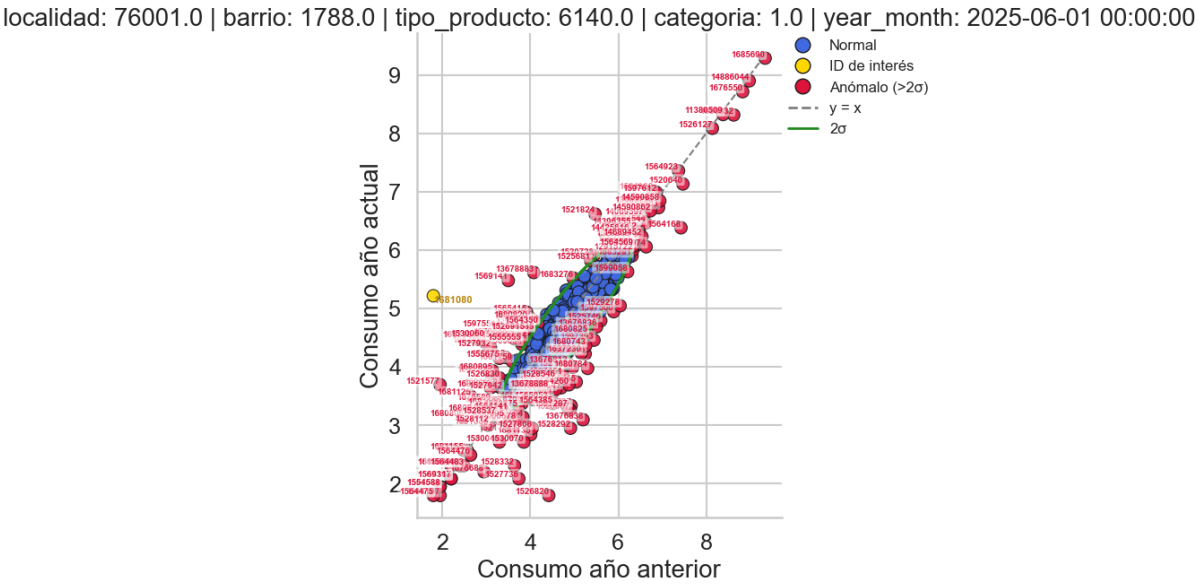

Figura 3: Ejemplo de agrupación de clientes con características similares. El punto de color amarillo identifica al cliente cuyo consumo es anómalo comparado con los de clientes semejantes.

De manera similar, por medio de los algoritmos de agrupación se pueden identificar patrones de consumo anómalos como el que muestra la Figura 4.

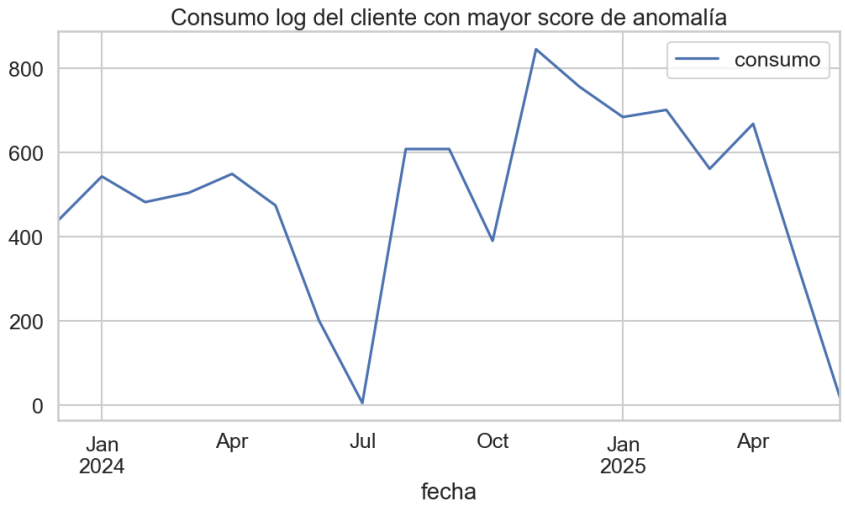

Figura 4: Cliente anómalo identificado por medio del algoritmo *Isolation Forest*.

5.2. Desempeño de Modelos Supervisados

El análisis de las matrices de confusión y métricas de desempeño obtenidas en el conjunto de prueba proporciona evidencia cuantitativa del desempeño de nuestros modelos supervisados. Los tres algoritmos implementados (Random Forest, Gradient Boosting (XGBoost) y LightGBM) exhiben capacidades discriminativas similares, con valores de AUC concentrados en el rango 0.709-0.710, lo que indica un nivel comparable de habilidad para distinguir entre usuarios anómalos y normales a través de todos los umbrales de clasificación posibles.

Random Forest alcanza una exactitud del 67.1 % y un AUC de 0.709. La matriz de confusión (Figura 6) muestra que el modelo logra identificar correctamente 310 casos anómalos de un total de 726 presentes en el conjunto de prueba, resultando en un recall del 42.7 % para la clase anómala. Simultáneamente, cuando Random Forest marca un usuario como sospechoso, la probabilidad de que efectivamente sea anómalo es del 63.1 % (precisión). Este balance entre recall y precisión se refleja en un F1-score de 0.509 para la detección de anomalías. El modelo muestra una capacidad razonable tanto para identificar anomalías como para evitar falsos positivos excesivos, clasificando correctamente 907 de los 1,088 usuarios normales como tales (especificidad del 83.4 %).

Gradient Boosting (XGBoost) presenta un AUC de 0.710 y una exactitud del 67.2 %. Sin embargo, su matriz de confusión revela un comportamiento marcadamente diferente al de Random Forest: alcanza un recall de apenas 23.3 % para anomalías (identificando solo 169 de 726 casos anómalos), pero compensa dramáticamente con una precisión excepcional de 81.6 %. Este perfil indica que XGBoost es extremadamente conservador al marcar usuarios como anómalos, priorizando fuertemente la minimización de falsos positivos sobre la cobertura. De hecho, el modelo clasifica correctamente 1,050 de los 1,088 usuarios normales (96.5 % de especificidad), cometiendo solo 38 falsos positivos. Este comportamiento puede ser estratégicamente útil en escenarios donde los recursos de inspección son muy limitados y se prioriza certeza absoluta sobre cobertura, aceptando que se perderán muchas anomalías reales a cambio de que casi todas

las inspecciones priorizadas resulten exitosas.

LightGBM emerge con un perfil equilibrado entre los dos anteriores, alcanzando una exactitud de 66.7 % y un AUC de 0.710. Para la detección de anomalías, LightGBM logra identificar 292 de los 726 casos anómalos (recall del 40.2 %) con una precisión del 63.2 %, representando un balance intermedio entre la cobertura de Random Forest y la precisión de XGBoost. El F1-score de 0.492 para la clase anómala confirma este equilibrio. LightGBM clasifica correctamente 918 de los 1,088 usuarios normales (84.4 % de especificidad), cometiendo 170 falsos positivos, un número intermedio entre Random Forest (181 falsos positivos) y XGBoost (38 falsos positivos).

Las curvas ROC de los tres modelos (Figura 5) confirman visualmente que los tres algoritmos tienen capacidades discriminativas prácticamente equivalentes, con sus curvas superponiéndose estrechamente y todos alcanzando AUC 0.71. Esta convergencia en el desempeño global sugiere que los tres métodos están capturando patrones similares en los datos de entrenamiento y que la diferencia en sus comportamientos específicos (conservador vs equilibrado) se debe principalmente a cómo establecen sus umbrales de decisión por defecto más que a diferencias fundamentales en su capacidad predictiva.

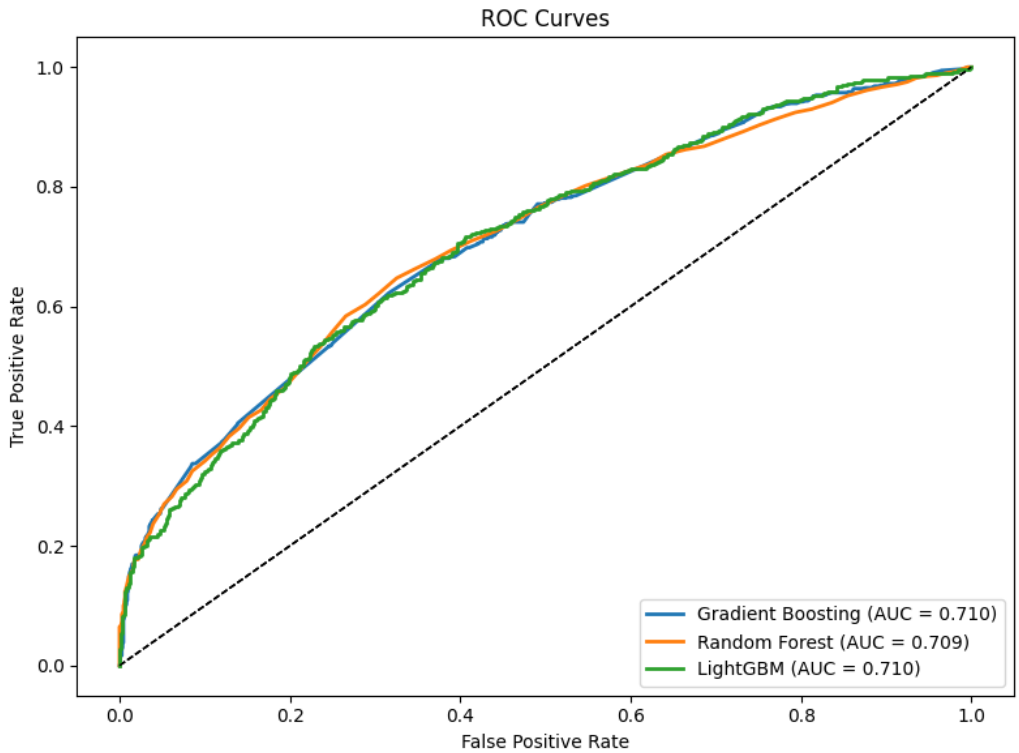

Figura 5: Curvas ROC de los tres modelos de clasificación supervisada. Los tres algoritmos exhiben capacidades discriminativas similares con AUC 0.71, indicando desempeño comparable en la distinción entre usuarios anómalos y normales a través de todos los umbrales posibles.

Es crucial mencionar que estas métricas corresponden a un umbral de clasificación específico de 0.5, pero en la práctica operativa, este umbral puede y debe ajustarse según las prioridades estratégicas de EMCALI. Un umbral más bajo (por ejemplo, 0.3) incrementará el recall, permitiendo detectar un mayor número de anomalías a costa de aumentar los falsos positivos y reducir la precisión. Conversely, un umbral más alto (por ejemplo, 0.7) incrementará la precisión,

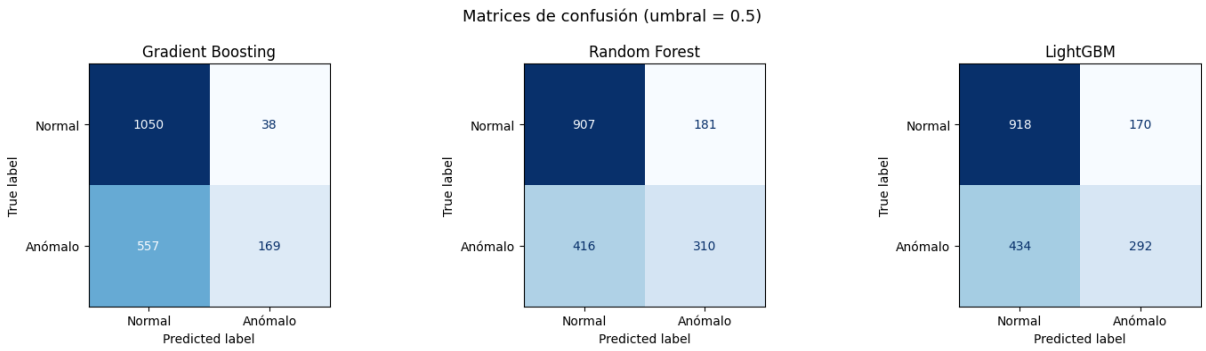

Figura 6: Matrices de confusión de los tres modelos supervisados evaluadas con umbral de clasificación = 0.5. Gradient Boosting muestra un perfil conservador (alta precisión, bajo recall), Random Forest un perfil equilibrado, y LightGBM una posición intermedia.

garantizando que casi todas las inspecciones priorizadas detecten irregularidades, pero a costa de perder cobertura sobre el universo total de anomalías existentes.

La ventaja del AUC como métrica de evaluación es que captura el desempeño del modelo de manera independiente del umbral de clasificación elegido, evaluando su capacidad discriminativa a través de todos los umbrales posibles simultáneamente. En este sentido, los tres modelos demuestran capacidades equivalentes (AUC 0.71), lo que significa que cualquiera de ellos puede ser ajustado mediante selección de umbral para alcanzar el punto específico en la curva de trade-off precisión-recall que mejor se alinee con los objetivos operativos de EMCALI.

6. Análisis de Impacto Económico

La implementación de sistemas de detección de anomalías debe justificarse desde una perspectiva económica. Esta sección presenta una metodología de valoración económica que traduce las detecciones en beneficios monetarios netos, considerando tanto ingresos recuperados como costos operativos. El análisis cuantifica el retorno de inversión tangible del sistema, optimizando la priorización de inspecciones por beneficio neto esperado.

6.1. Metodología de Cuantificación de Beneficios

La metodología integra cinco componentes que transforman predicciones del modelo en estimaciones monetarias:

1. Filtrado de Anomalías: De 31 categorías documentadas, se retienen solo aquellas donde: (a) existe alteración atribuible al usuario, y (b) el consumo real supera el facturado (subfacturación). Este criterio focaliza el análisis en casos genuinos de pérdidas recuperables. Las categorías utilizadas son:

1. 13 - SERVICIO DIRECTO
2. E_A1 - ACOMETIDA DERIVADA
3. D_A10 - ACOMETIDA DENTRO DEL TECHO
4. 12 - LINEA DIRECTA

5. 5 - ANOMALIA EN SELLOS DE TAPA PRINCIPAL
6. D_A2 - ACOMETIDA EMPALMADA
7. D_S5 - SIN SELLO BORNERA
8. 16E - MEDIDOR CON DISCO FRENADO
9. 4 - CONEXIÓN INADECUADA EN EL MEDIDOR
10. 16B - DERIVACIÓN DE ACOMETIDA
11. E_M13 - MEDIDOR ESTATICO CON DISPLAY APAGADO
12. E_M2 - ALTERACION DE LA POSICION DEL MEDIDOR
13. D_A4 - ACOMETIDA PELADA ANTES DEL MEDIDOR
14. 1 - PUENTE ENTRE ENTRADA Y SALIDA DE BOBINA
15. E_O7 - LÍNEA DIRECTA
16. D_S1 - SELLO BORNERA ROTO
17. E_A7 - SERVICIO DIRECTO CON MEDIDOR
18. E_A8 - SERVICIO CLANDESTINO
19. E_M8 - MEDIDOR CON DISCO FRENADO
20. E_M9 - MEDIDOR CON PUENTES EN BORNES
21. 16A - ALTERACIÓN EN LA POSICIÓN DEL MEDIDOR
22. 16C - EQUIPO DE MEDIDA CON ELEMENTOS EXTRAÑOS
23. E_M12 - MEDIDOR DAÑADO
24. E_M17 - MEDIDOR CON DIGITOS CORRIDOS
25. D_M7 - EQUIPOS RETIRADO POR PARTICULARES
26. E_S2 - SIN SELLOS DE TAPA PRINCIPAL
27. E_M11 - MEDIDOR CON REGISTRO TRABADO
28. 16F - MEDIDOR CON DISCO RAYADO
29. E_M24 - CONEXIÓN INADECUADA EN EL MEDIDOR
30. D_S4 - SELLOS DEJA HUELLA VIOLADOS
31. E_M10 - MEDIDOR CON REGISTRO CAMBIADO

2. Clustering: Se utiliza el método K-Modes para clusterizar las observaciones utilizando las variables categóricas disponibles: localidad, barrio, tipo de producto, categoría, subcategoría. K-modes es un algoritmo de agrupamiento no supervisado diseñado específicamente para trabajar con datos categóricos. A diferencia de K-means, que agrupa observaciones a partir de promedios y distancias euclidianas entre variables numéricas, K-modes utiliza la moda como representante de cada grupo y mide la similitud entre observaciones según la coincidencia o diferencia entre sus categorías.

El hiperparámetro más importante para K-modes es K, es decir el número de clusters. Para identificarlo, se utilizó el método del codo, con el cual se identifica que el número óptimo de clusters es $K = 10$.

3. Diferencia de Consumo por Cluster: Para cada cluster se calcula la diferencia entre el consumo de las observaciones no anómalas y las anómalas. Para eso se calcula la diferencia de las medianas, para evitar problemas de outliers. Para cada cluster se calcula por lo tanto:

$$d_c = \text{mediana}_{no-anomalo}(consumo) - \text{mediana}_{anomalo}(consumo).$$

Se filtraron aquellos clusters cuya diferencia es negativa, indicando que no se presenta un efecto positivo.

4. Análisis de beneficios por umbral: Para analizar el impacto económico general, utilizamos el modelo supervisado seleccionado (LightGBM) junto con las probabilidades asignadas por usuario. Se realiza un barrido de umbrales (0.1-0.95, incrementos 0.05), calculando para cada uno las métricas más relevantes: Verdaderos Positivos (TP), Falsos Positivos (FP), Precisión,

Recall y F1-Score.

Para cada umbral y cluster, además, se calcula el beneficio obtenido, siguiendo la fórmula

$$Beneficio_c = TP_c \times d_c \times 850 \times 85.36$$

donde 850 representa el valor promedio por kWh y 85.36 meses es el horizonte calculado como

$$\frac{1}{(1.15)^{1/12} - 1},$$

representando el valor presente a tasa de descuento del 15 % anual. Además, se calcula el costo de las visitas (predichos positivos) suponiendo un costo por visita de 50.000 pesos colombianos:

$$CostoTotal_c = (TP_c + FP_c) \times 50,000.$$

Finalmente, el beneficio neto es la diferencia entre el beneficio total y el costo total en cada cluster.

$$BeneficioNeto_c = Beneficio_c - CostoTotal_c.$$

Sumando los beneficios netos sobre todos los clusters obtenemos el beneficio total de cada umbral. El umbral seleccionado finalmente será el que maximice las ganancias para la identificación de las anomalías.

6.2. Resultados Económicos

El barrido sistemático de umbrales identificó que el umbral óptimo es 0.25, el cual maximiza el beneficio neto en $422.3 millones de pesos colombianos ($649.2M beneficio bruto - $252.7M costos). Esta configuración recomienda inspeccionar 5,053 usuarios (66 % del dataset validado) y genera un ROI de $2.45 pesos de beneficio bruto por cada peso invertido, o $1.45 netos. Las métricas operativas confirman la viabilidad del sistema: precisión de 39.1 %, recall de 96.3 % (detecta prácticamente todos los fraudes reales), y F1-Score de 55.7 %.

7. Conclusiones y Recomendaciones Estratégicas

7.1. Síntesis de Hallazgos y Valor Diferencial

La implementación de la metodología “tridimensional” de detección de anomalías en los diferentes segmentos de actividad económica de EMCALI ha demostrado capacidades distintivas que ofrecen valor operativo tangible. La integración de métodos grupales, individuales y supervisados es una arquitectura estratégicamente diseñada para capturar la heterogeneidad de manifestaciones que pueden tener las irregularidades en el consumo eléctrico de usuarios comerciales, industriales, oficiales y otros segmentos. Cada metodología aporta un tipo específico de inteligencia que, combinada con las demás, proporciona una cobertura diagnóstica sin preceden-

tes.

El valor diferencial de los métodos basados en agrupación reside en su capacidad para detectar anomalías colectivas que señalan problemas sistemáticos o fraudes organizados. Cuando un grupo completo de usuarios —independientemente de su actividad específica— conectados al mismo transformador exhibe simultáneamente comportamientos atípicos, la probabilidad de que se halle una situación de fraude coordinado, manipulación de infraestructura compartida, o falla masiva de medición es alta. Estos casos tienen un multiplicador de impacto: una sola intervención en el transformador puede resolver simultáneamente múltiples irregularidades, lo que permite maximizar el retorno sobre la inversión de cada visita de campo. Más aún, la detección de anomalías grupales proporciona información valiosa para la gestión de riesgos: permite identificar zonas geográficas, sectores industriales, áreas comerciales o segmentos de transformadores que requieren auditorías más frecuentes o vigilancia especial.

Los métodos individuales basados en análisis de series temporales complementan el enfoque grupal al capturar cambios estructurales en usuarios específicos que pueden no manifestarse como desviaciones respecto a grupos de referencia. Un establecimiento que opera legítimamente durante años y súbitamente experimenta una reducción abrupta y sostenida en su consumo sin justificación aparente representa una señal de alerta que requiere investigación, independientemente de cómo se comporten otros establecimientos similares o de su clasificación económica. La técnica CUSUM es particularmente efectiva para detectar estos cambios de régimen, mientras que los modelos de forecasting (SARIMAX, ETS, Prophet) proporcionan una evaluación probabilística rigurosa de cuán improbable es el consumo observado dado el historial del usuario. Estos métodos son esenciales para detectar fraudes individuales sofisticados y manipulaciones recientes que aún no han generado patrones lo suficientemente extremos como para destacar en comparaciones grupales.

El verdadero diferenciador competitivo de esta propuesta son los modelos supervisados de clasificación. Estos algoritmos representan la estandarización del conocimiento acumulado de EMCALI a través de años de inspecciones de campo en diversos tipos de usuarios. Cada caso investigado y confirmado como fraudulento —sea comercial, industrial u oficial— se convierte en un ejemplo de aprendizaje que entrena a los modelos para reconocer patrones sutiles y combinaciones específicas de características que distinguen a los usuarios anómalos. Esta capacidad de aprender de la experiencia significa que el sistema mejora continuamente: cada ciclo de inspecciones genera nuevos datos etiquetados que refinan los modelos, lo que hace las predicciones progresivamente más precisas y adaptadas a las particularidades del fraude en el contexto específico de EMCALI y de cada segmento de actividad. Los *scores* de probabilidad generados por *LightGBM*, el modelo de mejor desempeño con 64 % de exactitud, proporcionan una herramienta cuantitativa robusta para priorizar inspecciones, permitiendo a EMCALI maximizar la tasa de éxito de sus intervenciones.

7.2. Recomendaciones para Implementación y Escalamiento

La transición de estos resultados analíticos a impacto operativo tangible requiere una estrategia de implementación cuidadosamente diseñada. Se recomienda un enfoque por fases que permi-

ta validar empíricamente el valor del sistema mientras se construye confianza en los equipos técnicos y se ajustan procesos operativos. La primera fase debería consistir en un piloto focalizado donde se seleccionen los 100 usuarios con *scores* más altos según *LightGBM*, distribuyendo proporcionalmente entre diferentes segmentos de actividad económica y priorizando aquellos que también hayan sido marcados por métodos grupales (para maximizar probabilidad de éxito). Estas 100 inspecciones deben ser meticulosamente documentadas, registrando no solo si se encontró anomalía sino también el tipo específico de irregularidad, la magnitud estimada de pérdidas, el segmento de actividad, y cualquier característica observable que pueda enriquecer futuros entrenamientos.

Los resultados del piloto proporcionarán tres tipos de valor. Primero, una validación empírica de la tasa de precisión del sistema en condiciones operativas reales: es posible estimar cuántos de los 100 casos inspeccionados efectivamente resultaron anómalos, desagregando por tipo de actividad económica, lo cual calibrará las expectativas para el escalamiento. Segundo, una estimación del valor económico recuperable: sumando las pérdidas detectadas en los casos confirmados, es posible calcular el valor monetario por inspección y proyectar el retorno de inversión del sistema completo para cada segmento. Tercero, datos etiquetados adicionales de altísima calidad que pueden ser inmediatamente incorporados al reentrenamiento de los modelos, mejorando su desempeño para la siguiente fase y permitiendo ajustes específicos por tipo de actividad.

La segunda fase de implementación permitirá expandir el sistema a los 1,000 usuarios más prioritarios distribuidos entre los diferentes segmentos de actividad económica, integrando tanto *scores* de modelos supervisados como señales de métodos no supervisados mediante un sistema de *scoring* compuesto. En esta fase, es crucial implementar un proceso de retroalimentación sistemático donde cada inspección realizada alimente la base de datos de entrenamiento, lo que permite crear un flujo de mejora continua. En este punto, se recomienda establecer un protocolo donde los inspectores de campo completen un formulario estandarizado digital que capture no solo si el usuario es anómalo, sino también variables contextuales que puedan ser útiles para ingeniería de características futuras: antigüedad del medidor, accesibilidad de la instalación, características físicas del establecimiento, tipo específico de actividad económica dentro de cada segmento, entre otros.

La fase de escalamiento completo requiere integración del sistema de *scoring* con los sistemas de información empresarial de EMCALI. Técnicamente, esto implica desarrollar un pipeline automatizado que periódicamente (mensualmente o trimestralmente) tome los datos actualizados de consumo de todos los usuarios comerciales, ejecute los algoritmos de detección, y genere listas priorizadas de inspección que se integren con el sistema de órdenes de trabajo de campo. Esta automatización es esencial para que el sistema sea sostenible en el largo plazo sin requerir intervención manual de científicos de datos en cada ciclo operativo.

7.3. Oportunidades de Extensión y Mejora Continua

El sistema desarrollado para los diferentes segmentos de actividad económica de EMCALI representa una plataforma tecnológica que puede ser extendida en múltiples direcciones para amplificar su impacto. Una extensión natural es la refinación y especialización de metodologías

para subsegmentos específicos dentro de cada categoría: por ejemplo, dentro del segmento comercial, desarrollar modelos específicos para restaurantes, hoteles, supermercados y oficinas; dentro del industrial, distinguir entre manufactura ligera, procesamiento químico, o ensamblaje; dentro del oficial, diferenciar entre instituciones educativas, hospitalarias y administrativas. Cada subsegmento tiene características distintivas que permitirían modelos aún más precisos, aunque la arquitectura conceptual de combinar métodos grupales, individuales y supervisados es universalmente aplicable.

Una segunda oportunidad de extensión es la incorporación de fuentes de datos adicionales que actualmente no están siendo explotadas. Información sobre reclamos de usuarios, historial de suspensiones y reconexiones, datos de calidad de servicio (interrupciones, voltaje), información catastral actualizada sobre características de los establecimientos, registros de cámara de comercio sobre actividad económica, y datos climáticos (que afectan consumos en establecimientos con aire acondicionado, refrigeración o procesos térmicos) podrían ser integrados como variables explicativas adicionales que enriquezcan los modelos supervisados. Cada nueva fuente de datos potencialmente captura señales complementarias que mejoran la capacidad predictiva.

Finalmente, la evolución hacia sistemas de monitoreo en tiempo real o cuasi-real representa el horizonte más avanzado. Con la eventual implantación de medidores inteligentes (smart meters) que transmiten datos de consumo con frecuencias mucho mayores (horaria o subhoraria en lugar de mensual), será posible detectar anomalías con latencias mucho menores. Un fraude que actualmente podría pasar desapercibido durante meses hasta la próxima lectura podría ser detectado en días o semanas con datos de alta frecuencia, minimizando las pérdidas acumuladas. Los modelos de series temporales implementados (SARIMAX, Prophet) y los algoritmos de clasificación (LightGBM) son directamente extensibles a datos de mayor frecuencia, lo que significa que la inversión en la plataforma actual es resiliente ante estas futuras evoluciones tecnológicas.

7.4. Mensaje Final: Una Inversión en Inteligencia Operativa

En síntesis, la solución que se presenta en este documento no es simplemente un conjunto de modelos estadísticos sino una plataforma integral de inteligencia operativa que transforma datos de consumo eléctrico en acción priorizada para todos los segmentos de actividad económica. El valor de esta transformación se manifiesta en múltiples dimensiones: recuperación directa de ingresos mediante detección de fraudes en comercios, industrias e instituciones, reducción de pérdidas no técnicas, optimización de recursos de inspección, identificación de problemas de infraestructura, y generación de información estratégica para la gestión de riesgos en cada tipo de usuario.

Los resultados cuantitativos obtenidos —exactitudes superiores al 60 % en modelos supervisados, identificación de cientos de usuarios potencialmente anómalos mediante métodos grupales e individuales en diversos segmentos— demuestran que el sistema tiene capacidad predictiva real y valor operativo inmediato. Más importante aún, la arquitectura de aprendizaje continuo garantiza que este valor no es estático sino creciente: cada ciclo de inspecciones fortalece los modelos, cada nuevo usuario etiquetado mejora las predicciones, cada refinamiento en la calidad de datos incrementa la precisión. Esto convierte la implementación no en un gasto sino en una

inversión que genera retornos compuestos en el tiempo, independientemente del segmento de actividad económica.

Para EMCALI, adoptar esta solución significa posicionarse en la frontera tecnológica de las empresas de servicios públicos en América Latina. Representa la evolución de procesos reactivos de control basados en denuncias o inspecciones aleatorias hacia un modelo proactivo y basado en evidencia donde las decisiones de campo son guiadas por inteligencia artificial entrenada con la experiencia acumulada de la organización. Es, fundamentalmente, una inversión en eficiencia operativa, sostenibilidad financiera, y equidad tarifaria que beneficia tanto a la empresa como a sus usuarios legítimos de todos los segmentos económicos.

Referencias

Kharal, A.Y., Khalid, H.A., Gastli, A., & Guerrero, J.M. (2021). A novel features-based multivariate Gaussian distribution method for the fraudulent consumers detection in the power utilities of developing countries. *IEEE Access*, 9, 81057–81067. doi:10.1109/ACCESS.2021.3085501